

Какой сервер нужен под защиту от подделки лица

Расчёт конфигурации второго выделенного сервера (ЦОД Алмалык) под ML-нагрузку антиспуф-системы — по фактическим замерам, не по догадкам.

Короткий вывод: CPU-сервер архитектурно не держит целевой UX-бюджет (5–6 сек на проверку) уже при **двух одновременных проверках** — это не гипотеза о будущем масштабе, это свойство самой модели уже сегодня. GPU-карта среднего класса закрывает вопрос с большим запасом на все обозримые сценарии нагрузки.

1. Зачем вообще отдельный сервер

Антиспуф-модуль — это не косметика, а барьер против конкретной уже случившейся атаки: обход проверки лица инспектора статичным фото. Чтобы барьер держал реальную нагрузку в поле (десятки точек продажи баллонов одновременно), под него нужна предсказуемая, изолированная вычислительная мощность — не общий сервер API, который параллельно тянет базу данных и остальной бизнес-трафик.

2. Что мы реально замерыли

Все числа ниже — не прогноз, а живые измерения на модели **AdaFace IR-101** (та самая нейросеть, которая сверяет лицо инспектора), снятые сегодня на процессоре Intel i5-11400 (6 ядер / 12 потоков).

Стадия проверки	Время на 1 кадр
Детекция лица + ключевые точки (SCRFD)	ФАКТ ~100–160 мс
Сверка личности (AdaFace IR-101), тёплый прогон	ФАКТ ~342 мс
Сверка личности, единичный/холодный вызов	ФАКТ ~524 мс
Проверка на подделку (passive-PAD)	ФАКТ ~20 мс

Одна проверка живости требует 4–6 таких кадров подряд. Итог — **чистое время вычислений на одну проверку: 1,85–4,2 секунды**, и это на процессоре, который в моменте занят ровно одной проверкой, без очереди.

Контекст бюджета

Целевое время всей проверки (от старта до вердикта, включая сам поворот головы инспектором) — 5–6 секунд. То есть в лучшем случае, без всякой очереди, вычисления уже съедают 30–70% всего допустимого времени.

3. Находка, которая меняет всё: CPU не масштабируется по ядрам

Это не оценка на будущее — это факт архитектуры прямо в текущем коде. Нейросеть AdaFace при запуске не ограничена в потоках и по умолчанию пытается забрать **все** доступные ядра процессора на **одну** проверку. Когда приходит вторая проверка одновременно (второй инспектор в другом районе, в ту же секунду) — они не выполняются параллельно на разных ядрах бесплатно, они **дерутся за один и тот же пул потоков**.

Одновременных проверок	Оценка времени на проверку	Укладывается в 5–6 сек?
1	ФАКТ 1,85–4,2 с	на грани
2	ОЦЕНКА 3,7–8,4 с	уже нет
3	ОЦЕНКА 5,6–12,6 с	нет
5	ОЦЕНКА 9–21 с	нет, кратно

Почему это важно именно для решения о железе

Средняя часовая нагрузка (10, 50 или даже 200 проверок в час) сама по себе — не проблема: сервер простаивает большую часть времени. Проблема —

пиковые совпадения

: пересменка, несколько точек продажи сработали в одну и ту же секунду. При сети точек по всей области такие совпадения — норма, а не редкое исключение. И уже на второй одновременной проверке процессорный вариант перестаёт укладываться в целевое время.

4. Два пути — и почему один из них тупиковый

⚠ Остаться на CPU

- Держит только строго последовательные, не пересекающиеся по времени проверки
- Любые 2+ одновременных запроса — гарантированное превышение UX-бюджета
- «Больше ядер» не спасает — упирается в архитектуру самой модели, а не в число ядер
- Единственный реальный выход на CPU — облегчённая модель (IR-18/IR-50), которой у нас физически нет: не обучена и не экспортирована

✓ Отдельная GPU-карта

- Тот же класс модели на GPU — типовое ускорение 5–20× (общееинженерная практика для таких сетей)
- Оценочное время проверки: **0,2–0,5 сек** вместо 1,85–4,2 сек
- Даже нереалистичный пик — 20 проверок одновременно разом — укладывается в 6–10 сек на всю пачку
- Один раз решает вопрос на все три сценария нагрузки (10, 50, 200+/час) с запасом

5. Рекомендуемая конфигурация

Итоговый расчёт под аренду в ЦОД

Компонент	Рекомендация	Почему
GPU	1× NVIDIA T4 (16 ГБ)	Самая распространённая и обычно самая доступная в аренде inference-карта; штатная поддержка нужного ПО (ONNX Runtime / TensorRT); низкое энергопотребление

Альтернатива GPU	NVIDIA A2000 / A4000 (16 ГБ)	Тот же класс задач, если T4 недоступна в аренде именно в этом ЦОД
CPU	6–8 vCPU	Модель больше не узкое место — процессор нужен только под сервис/сеть/ОС
RAM	16–32 ГБ	Запас под процессы и очереди
Диск	100–200 ГБ NVMe	Веса моделей — не более 300 МБ суммарно, диск не бутылочное горлышко; запас под логи

Фактическая видеопамять под саму нагрузку — существенно меньше 2 ГБ (веса модели ~260 МБ + служебные буферы CUDA). Карта на 16 ГБ взята с большим запасом на будущее — не для этой единственной задачи, а на случай переноса на GPU других ML-сервисов (распознавание документов, поиск по галерее лиц), если такой план появится.

6. Что нужно сделать в коде — независимо от выбора железа

Покупка GPU сама по себе проблему не решит без трёх правок на нашей стороне — они уже запланированы:

- Переключить модель распознавания на использование GPU вместо жёстко зашитого CPU-режима
- Поставить общий лимит одновременных проверок вместо нынешней защиты «по одному IP» (она не спасает от совпадения разных точек продажи)
- Прогнать реальный нагрузочный тест на арендованной GPU перед финальным подтверждением конфигурации — заменить инженерную оценку ускорения на измеренный факт

Как снизить риск перед подпиской на долгосрочную аренду

Большинство дата-центров дают короткую/почасовую пробную аренду GPU. Разумный следующий шаг — взять T4 или аналог на пробный период, прогнать реальный нагрузочный тест по цифрам из раздела 3, и только затем подтверждать конфигурацию на долгий срок. Это стоит недорого и убирает последнюю неопределённость в расчёте.

E-GAZ 2 · Антиспуф-система · Расчёт основан на живых замерах AdaFace IR-101 от 17.07.2026. Оценочные (не измеренные) цифры отмечены отдельно и получены по общеинженерным правилам для данного класса нейросетей — окончательная точность будет подтверждена нагрузочным тестом на реальной GPU перед долгосрочной подпиской.